

KI mit Python

Programmier Assignemt 2

Sommersemester 2026

Projektübersicht

Sie sind leitende Data Scientistin bzw. leitender Data Scientist bei *CoffeeTime*, einer großen europäischen Kaffeekeite mit Filialen in Deutschland, Frankreich und Polen. Im Jahr 2025 plant das Unternehmen eine Expansion durch die Eröffnung von **fünf neuen Filialen in Deutschland**. Ihre Aufgabe ist es, datengetriebene Methoden einzusetzen, um optimale Standorte für diese neuen Filialen zu empfehlen.

Ihnen stehen zwei Datensätze zur Verfügung:

1. **coffee_chain_stores_2024.csv** — Dieser Datensatz enthält *synthetisch generierte* historische Daten zu Kaffeeketten-Filialen in Deutschland, Frankreich und Polen für das Jahr 2024.
2. **potential_store_locations_germany.csv** — Dieser Datensatz enthält *synthetisch generierte* demografische, geografische und wirtschaftliche Informationen zu potenziellen Standorten in Deutschland.

Zielsetzung

Trainieren Sie ein lineares oder polynomiales Regressionsmodell auf Basis der historischen Leistungsdaten, um die **erwartete Rentabilität** einer neuen Filiale anhand von Standort- und demografischen Merkmalen vorherzusagen. Nutzen Sie dieses Modell, um potenzielle Standorte in Deutschland zu bewerten und zu rangieren, und **empfehlen Sie der Geschäftsführung die fünf besten Standorte**. Ihre Empfehlung muss eine kritische Reflexion der Modellgrenzen und realer Einflussfaktoren enthalten.

Modellierungsablauf

Sie sollen eine klare und reproduzierbare Data-Science-Pipeline umsetzen:

1. **Daten laden und verstehen:** Erkunden und visualisieren Sie beide Datensätze, um Verteilungen, Wertebereiche und mögliche Datenqualitätsprobleme zu verstehen.

2. **Vorverarbeitung:** Behandeln Sie fehlende Werte, kodieren Sie kategoriale Merkmale, skalieren bzw. normalisieren Sie numerische Variablen und führen Sie bei Bedarf Feature Engineering durch.
3. **Datenaufteilung:** Teilen Sie den historischen Datensatz in Trainings- und Testsatz auf oder verwenden Sie Kreuzvalidierung zur Modellbewertung.
4. **Initiales Modell trainieren:** Beginnen Sie mit einer einfachen linearen Regression und beurteilen Sie die Modellgüte.
5. **Modell validieren:** Verwenden Sie Evaluierungsmetriken wie MSE und R^2 zur Leistungsbewertung.
6. **Modell anpassen:** Erkunden Sie polynomiale Regression, variieren Sie Merkmalsätze oder führen Sie weiteres Feature Engineering durch, um die Vorhersagegenauigkeit zu verbessern.
7. **Erneutes Training und iterative Verbesserung:** Verfeinern Sie Ihr Modell durch mehrere Iterationen, geleitet von Hold-out-Validierungs- oder Kreuzvalidierungsergebnissen sowie diagnostischen Plots.

Sobald Sie Ihr finales Modell trainiert und validiert haben, verwenden Sie es, um die erwartete Rentabilität für die potenziellen Filialstandorte in Deutschland vorherzusagen.

Überlegungen und Einschränkungen

Obwohl die Modellierung datengestützte Erkenntnisse liefert, sollten bei der endgültigen Entscheidung folgende Faktoren berücksichtigt werden:

- Nicht beobachtbare Einflussfaktoren
- Saisonalität oder zukünftige Trends, die in den Daten von 2024 nicht abgebildet sind
- Datenqualität, z. B. mögliche Verzerrungen in den Standortmerkmalen
- Modellannahmen (z. B. lineare Zusammenhänge)

Abgabe

- Bilden Sie Gruppen von **bis zu 5 Studierenden**.
- Jede Gruppe gibt Folgendes ab:
 - Ein gut dokumentiertes **Python-Skript oder Jupyter Notebook**, das alle Schritte der Modellierungspipeline umsetzt.

- Ein **PDF-Dokument**, das der Geschäftsführung die finale Empfehlung kommuniziert, die Wahl der fünf Standorte begründet und die Grenzen des Modells diskutiert.
- Die **Abgabe ist für alle Studierenden verpflichtend**.
- Reichen Sie Ihre Lösung über **Moodle** ein.
- Geben Sie an, zu welcher Gruppe die eingereichte Lösung gehört.
- Abgabefristen:
 - WWIMBIT23A: **28.05.2026, 12.00 Uhr**
 - WWIMBIT23B: **28.05.2026, 12.00 Uhr**